

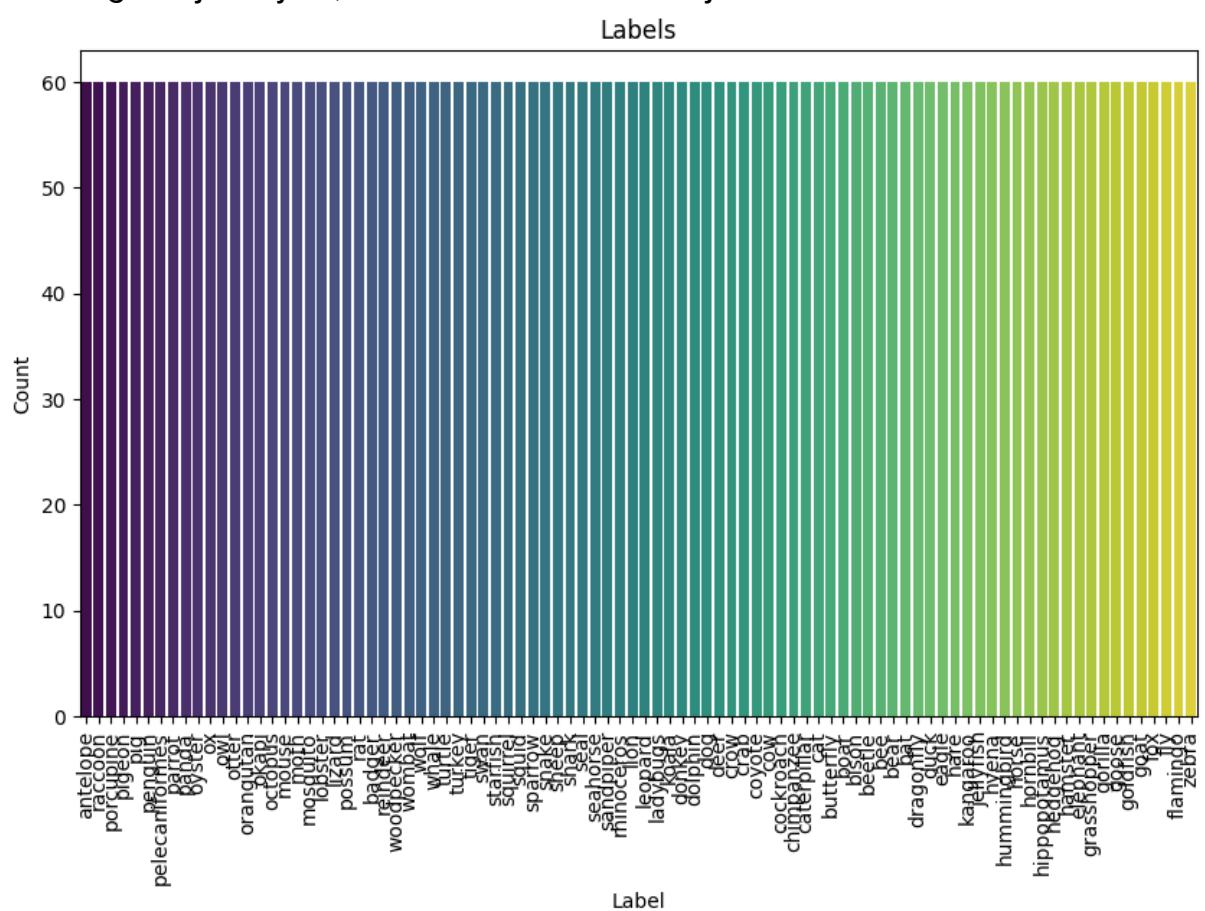
Zadanie 3

Úvod do problematiky

V prvej časti úlohy sme najprv zobrazili reprezentanta z každej triedy, potom sme získali predikcie pomocou predtrénovanej siete pre problém ImageNet a analyzovali sme výsledky. Druhá úloha zahŕňala získavanie a predspracovanie dát, návrh a vytvorenie vlastnej konvolučnej siete. Túto sieť sme potom trénovali na získaných dátach a porovnávali sme výsledky pri rôznych hyperparametroch. V druhej časti úlohy sme sa sústredili na zlepšenie výsledkov s využitím princípov transfer learning, pričom sme použili vybraný zhlukovací algoritmus. Posledná úloha spočívala v použití jedného z klasifikátorov z predchádzajúcej úlohy. Na trénovanie tohto klasifikátora sme použili príznaky, ktoré boli extrahované pomocou siete z prvej úlohy.

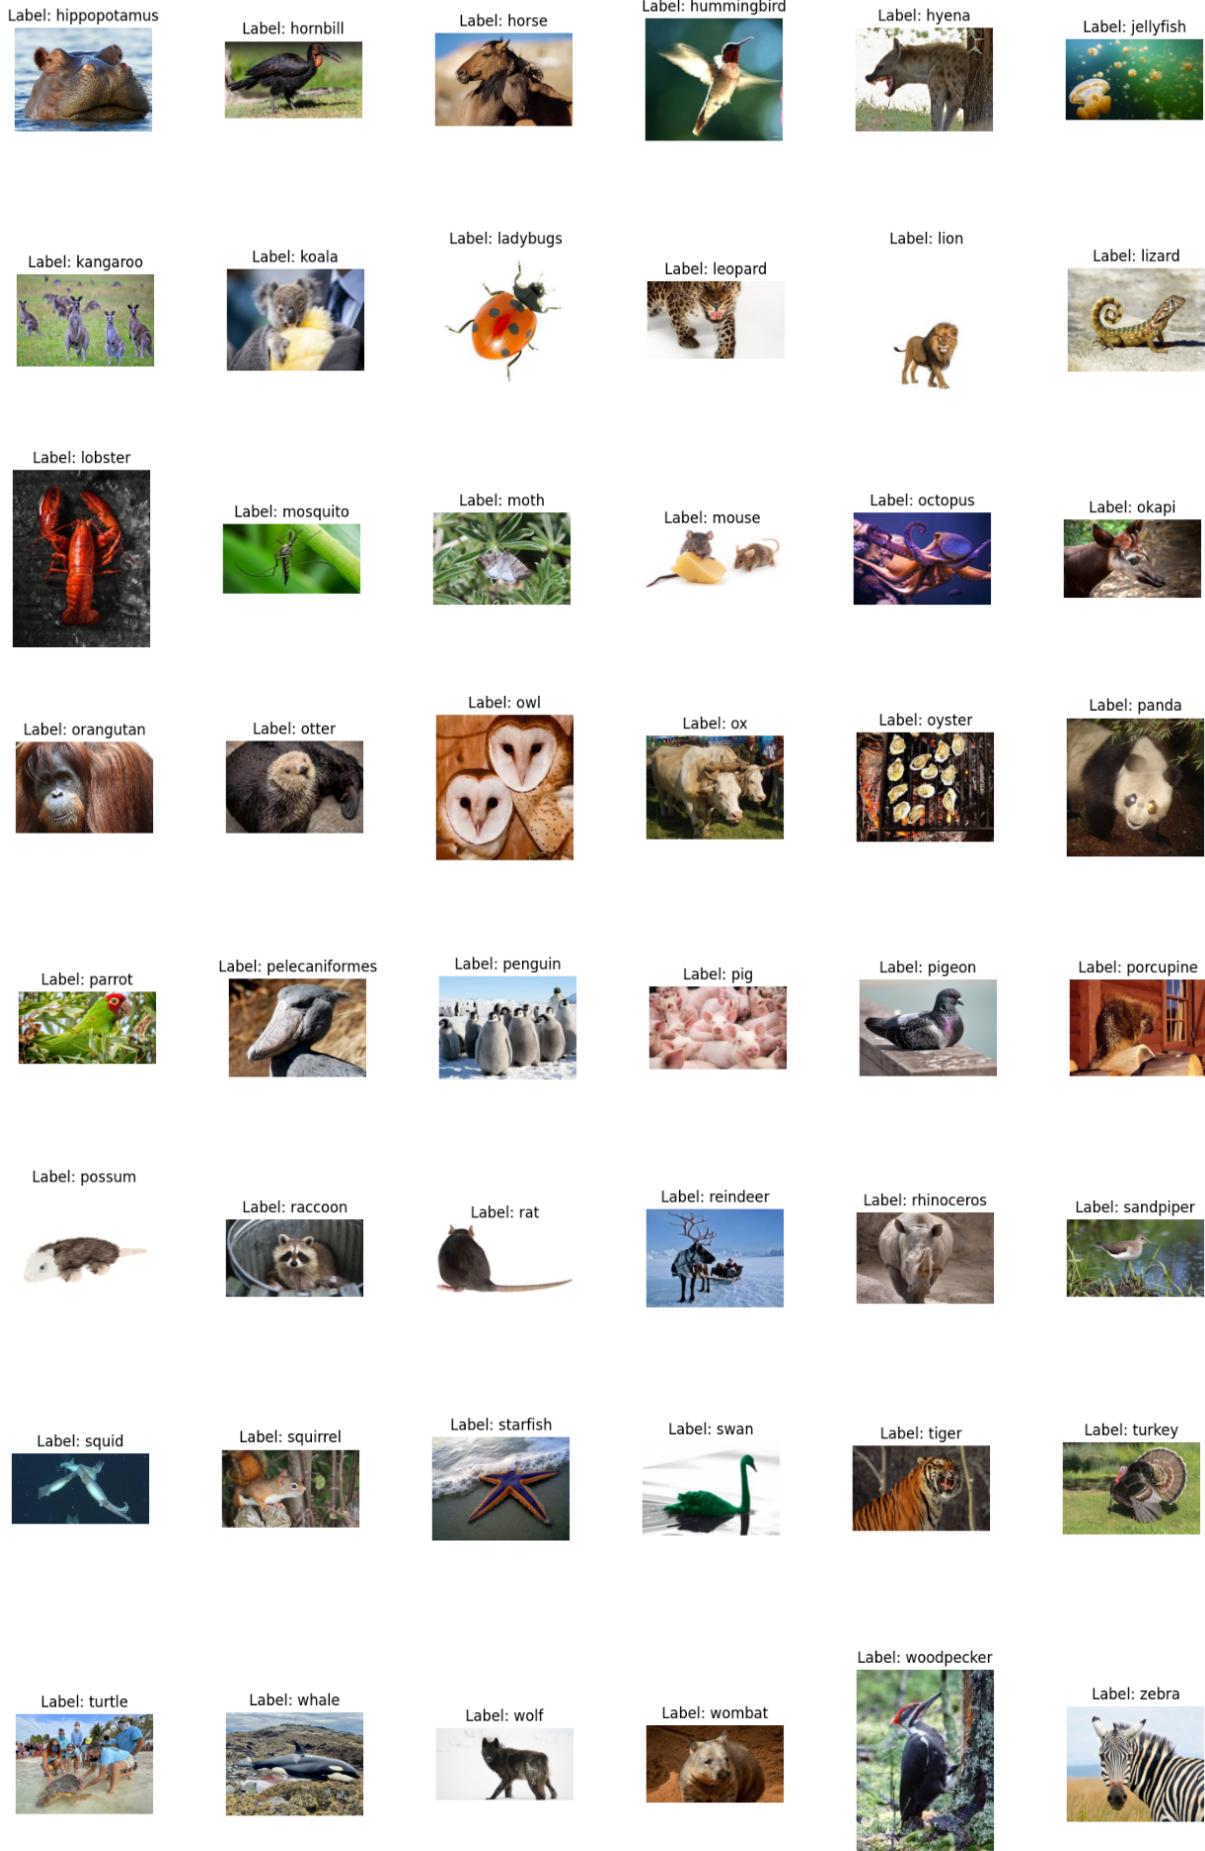
○ Analýza dát

Trénovacie a testovacie datasety boli spojené a následne analyzované. Dátová sada obsahuje 90 výstupných kategorických hodnôt. Celkovo dátová sada zahŕňa 5400 záznamov. Z nasledujúceho grafu je zrejmé, že každá trieda obsahuje 60 záznamov.



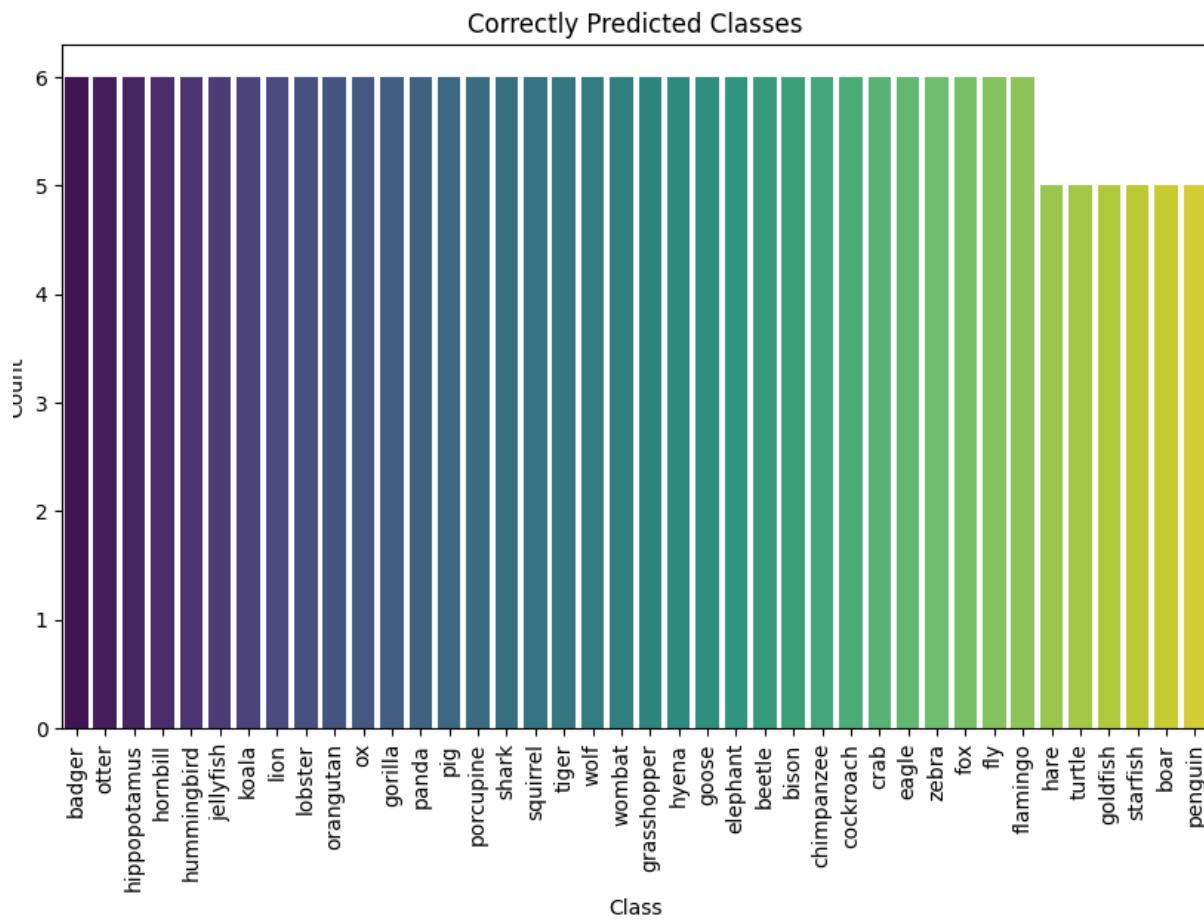
Následne zobrazíme obrázok z každej triedy:





- Analýza triedy podľa predpovedí

Načítali sme testovací dataset a vyhodnotili sme ho na modeli ResNet50 s nastavením obrazkovej transformácie, ktorá bola použitá na ImageNet, aby bola aplikovateľná aj na naše dátu. Nastavili sme tiež váhy, ktoré boli natrénované na datasete ImageNet. Na nasledujúcom obrázku môžeme vidieť 40 tried, z ktorých 34 malo 6 správnych predikcií.



Úspešnosť modelu na naše dátu bola nasledovná: testovací dataset obsahoval 524 záznamov, z ktorých 283 bol správne zaradený do príslušnej kategórie, zatiaľ čo 241 záznamov bolo zaradených nesprávne. Ďalej sa podarilo správne predpovedať tieto triedy: 'jazvec', 'medved', 'včela', 'chrobák', 'bizon', 'diviak', 'motýl', 'mačka', 'šimpanz', 'šváb', 'kojot', 'krab', 'vážka', 'kačica', 'orol', 'slon', 'plameniak', 'muchá', 'líška', 'zlatá rybka', 'hus', 'gorila', 'koník', 'škrečok', 'zajac', 'hroch', 'nosorožec', 'kolibrík', 'hyena', 'medúza', 'koala', 'leopard', 'lev', 'jašterica',

'homár', 'myš', 'orangutan', 'vydra', 'sova', 'vôl', 'panda', 'papagáj', 'tučniak', 'prasica', 'ježura', 'žralok', 'had', 'veverička', 'morská hviezda', 'labut', 'tiger', 'korytnačka', 'veľryba', 'vlk', 'vačica', 'zebra'.

- [Vytvorenie vlastnej konvolučnej sieti](#)

Najprv sme načítali trénovací a testovací dataset. Trénovací dataset sme následne rozdelili v pomere 8:2 na trénovací a validačný dataset. Pri načítaní sme všetky obrázky zmenšili na rozmer 224x224. Na normalizáciu sme najskôr prešli všetkými obrázkami a vypočítali sme priemerné hodnoty (mean) a štandardné odchýlky (std). Následne sme tieto hodnoty použili na normalizáciu obrázkov. Veľkosť dávky (batch size) sme nastavili na 32.

Model MyCNN je konvolučná neurónová sieť s nasledujúcou konfiguráciou:

```
MyCNN(  
    (conv1): Conv2d(3, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
    (conv1_bn): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)  
    (conv2): Conv2d(64, 128, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
    (conv2_bn): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)  
    (conv3): Conv2d(128, 256, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
    (conv3_bn): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)  
    (conv4): Conv2d(256, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
    (conv4_bn): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)  
    (pool): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)  
    (fc1): Linear(in_features=100352, out_features=1024, bias=True)  
    (fc1_bn): BatchNorm1d(1024, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)  
    (fc2): Linear(in_features=1024, out_features=512, bias=True)  
    (fc2_bn): BatchNorm1d(512, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)  
    (fc3): Linear(in_features=512, out_features=90, bias=True)  
    (dropout): Dropout(p=0.5, inplace=False)  
)
```

- **Konvolučné vrstvy:**

- conv1: 64 výstupných kanálov, 3x3 veľkosť filtra, krok 1, vycpávka 1
 - conv2: 128 výstupných kanálov, 3x3 veľkosť filtra, krok 1, vycpávka 1
 - conv3: 256 výstupných kanálov, 3x3 veľkosť filtra, krok 1, vycpávka 1
 - conv4: 512 výstupných kanálov, 3x3 veľkosť filtra, krok 1, vycpávka 1

- **Max Pooling vrstva (pool1)**: veľkosť filtra 2×2 , krok 2

- **Plne prepojené vrstvy**:

- $fc1$: 100352 vstupných prvkov, 1024 výstupných prvkov
- $fc2$: 1024 vstupných prvkov, 512 výstupných prvkov
- $fc3$: 512 vstupných prvkov, 90 výstupných prvkov

- **Dropout vrstva (dropout)**: s pravdepodobnosťou vynechávania

0.5

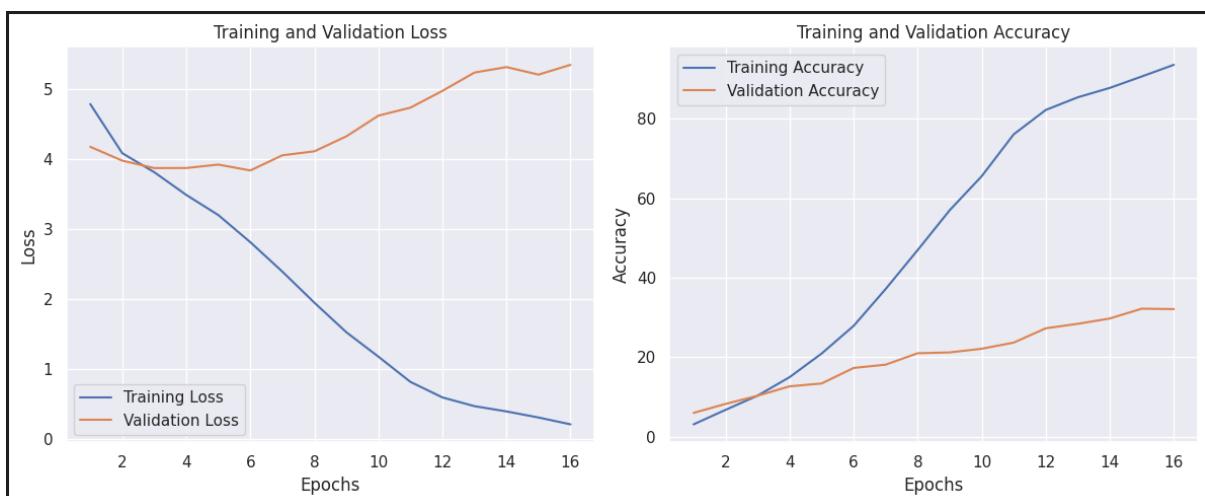
- **Vrstvy dávkovej normalizácie**: po každej konvolučnej a plne prepojenej vrstve krom poslednej.

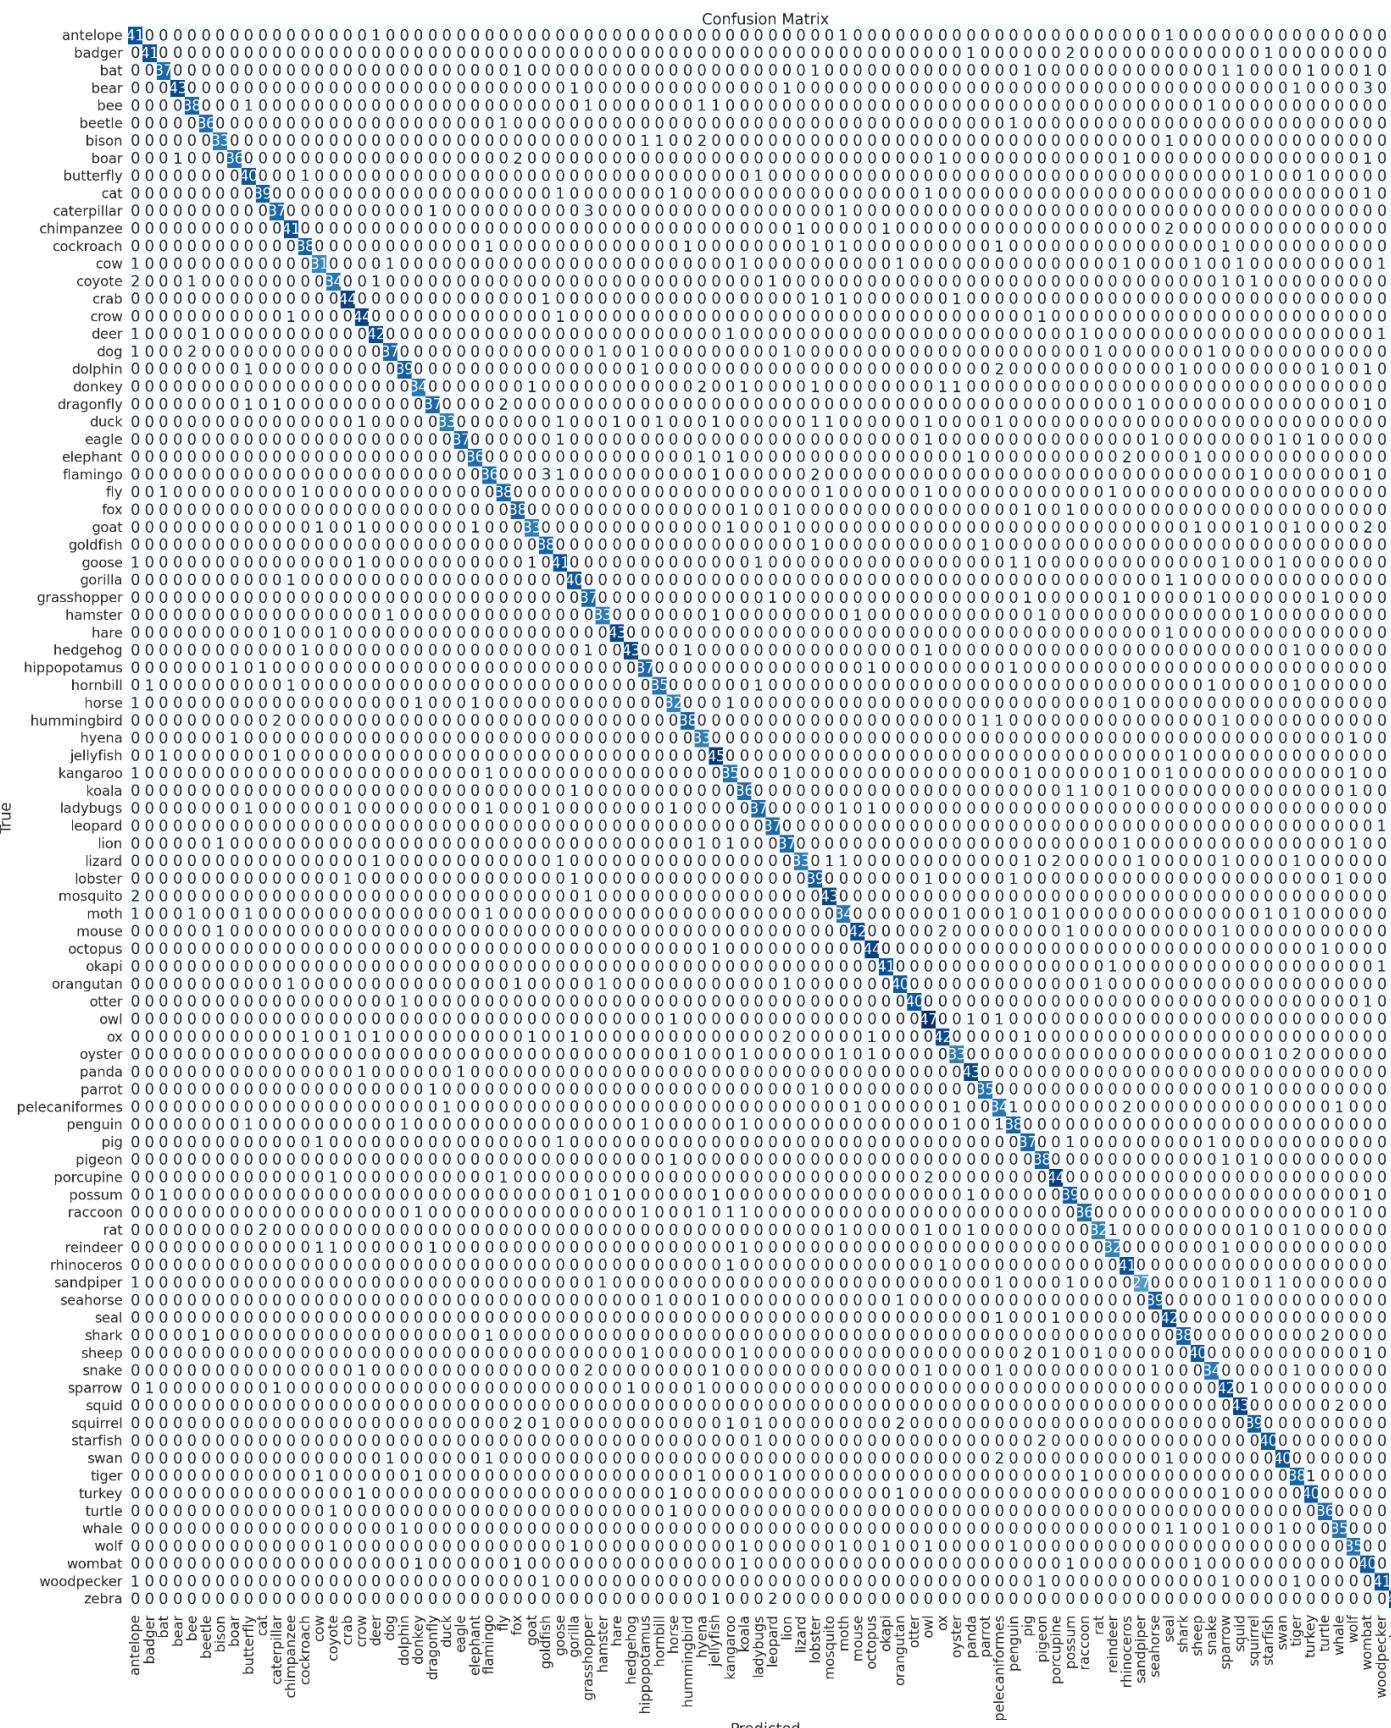
Čo sa týka predčasného ukončenia trénovania (early stopping), je nastavené s trpezlivosťou (patience) na 10 epoch, čo znamená, že trénovanie bude zastavené, ak sa chyba na validačnej množine nezlepší počas 10 po sebe idúcich epoch.

Našu sieť sme natrénovali na šiestich rôznych súpravách hyperparametrov na našich dátových súboroch. Ich výsledky sú zobrazené v nasledujúcej tabuľke:

Model	Learning Rate	Dropout	Batch Size	Train Accuracy (%)	Validation Accuracy (%)	Test Accuracy (%)
Model 1	0.001	0.5	32	84.83	85.19	15.00
Model 2	0.001	0.3	32	85.39	86.01	13.52
Model 3	0.001	0.2	32	84.52	86.11	14.81
Model 4	0.01	0.5	32	68.29	71.09	9.63
Model 5	0.01	0.3	32	46.84	49.79	7.59
Model 6	0.01	0.2	32	85.21	86.63	18.15

V ďalšej časti prezentácie sa zameriame výhradne na výsledky najlepšieho modelu. Ukážeme grafy, ktoré dokumentujú jeho tréningový proces, konkrétnie grafy strát (loss) a presnosti (accuracy). Následne predstavíme konfúzne matice pre trénovaciu a testovaciu množinu.





Confusion Matrix	
antelope	3
badger	0
bat	0
bear	1
bee	0
beetle	0
bison	3
boar	0
butterfly	0
cat	0
caterpillar	2
chimpanzee	0
cockroach	5
cow	1
coyote	0
crab	2
crow	0
deer	1
dolphin	0
donkey	1
dragonfly	0
duck	1
eagle	0
elephant	0
flamingo	5
fly	0
fox	0
goat	3
goldfish	0
goose	0
gorilla	3
grasshopper	0
hamster	0
hare	1
hedgehog	0
hippopotamus	5
hornbill	0
horse	0
hummingbird	2
hyena	0
jellyfish	0
kangaroo	1
koala	0
ladybugs	0
leopard	0
lion	0
lizard	0
lobster	0
mosquito	0
moth	0
mouse	0
octopus	0
okapi	0
orangutan	0
otter	0
owl	0
ox	0
oyster	0
panda	0
parrot	0
secaniformes	0
penguin	0
pig	0
pigeon	0
porcupine	0
possum	0
raccoon	0
rat	0
reindeer	0
rhinoceros	0
sandpiper	0
seahorse	0
seal	0
shark	0
sheep	0
snake	0
sparrow	0
squid	0
squirrel	0
starfish	0
swan	0
tiger	0
turkey	0
turtle	0
whale	0
wolf	0
wombat	0
woodpecker	0
zebra	0
antelope	3
badger	0
bat	2
bear	1
bee	0
beetle	3
bison	0
boar	3
butterfly	4
cat	1
caterpillar	2
chimpanzee	0
cockroach	5
cow	0
coyote	1
crab	0
crow	0
deer	1
dolphin	0
donkey	0
dragonfly	0
duck	1
eagle	0
elephant	3
flamingo	0
fly	5
fox	0
goat	0
goldfish	3
goose	3
gorilla	0
grasshopper	0
hamster	0
hare	0
hedgehog	2
hippopotamus	0
hornbill	1
horse	0
hummingbird	3
hyena	0
jellyfish	0
kangaroo	5
koala	0
ladybugs	0
leopard	0
lion	0
lizard	0
mosquito	6
moth	0
mouse	2
octopus	4
okapi	5
orangutan	0
otter	0
owl	0
ox	1
oyster	0
panda	0
parrot	2
secaniformes	0
penguin	0
pig	1
pigeon	1
porcupine	1
possum	0
raccoon	1
rat	1
reindeer	0
rhinoceros	0
sandpiper	0
seahorse	0
seal	0
shark	0
sheep	0
snake	2
sparrow	0
squid	0
squirrel	0
starfish	0
swan	0
tiger	1
turkey	0
turtle	1
whale	0
wolf	0
wombat	0
woodpecker	0
zebra	5

Predicted

- Generovanie príznakov pomocou sieti natrenovane na ImageNetu

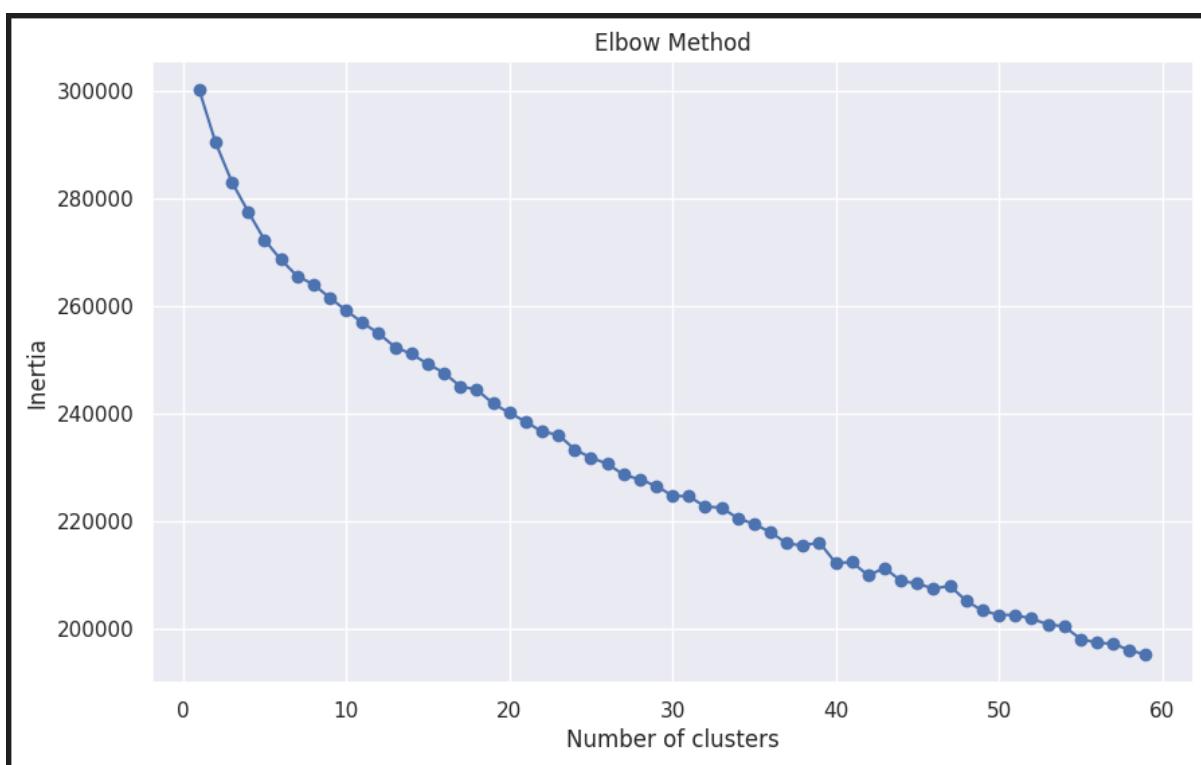
Vyššie spomenutú sieť, ktorá bola trénovaná na dátovom súbore ImageNet, som využil na generovanie príznakov. Pri generovaní príznakov som načítal nielen cestu k obrázkom, ale aj hodnotu štítku, v dôsledku čoho som získal dátový rámec obsahujúci 4860 záznamov a 2050 stĺpcov, ktorý vyzerá nasledovne:

	image_path	label	feature_1	feature_2	feature_3	feature_4	feature_5	feature_6	feature_7	feature_8	feature_2039	feature_2040	feature_2041	feature_2042	feature_2043	feature_2044	feature_2045	feature_2046	feature_2047	feature_2048	
0	z3_data/train/antelope/03d7f0088.jpg	antelope	0.0	0.029436	0.022404	0.0	0.000000	0.000000	0.004612	0.028869	...	0.000000	0.046245	0.000138	0.00586	0.000000	0.007993	0.0	0.000000	0.007514	0.019302
1	z3_data/train/antelope/03a37838e99.jpg	antelope	0.0	0.000000	0.000000	0.0	0.106369	0.000000	0.041993	0.000000	...	0.081651	0.000000	0.000000	0.000000	0.009675	0.0	0.000000	0.000000	0.022446	
2	z3_data/train/antelope/0b1a3af197.jpg	antelope	0.0	0.000000	0.000000	0.0	0.000000	0.000000	0.000000	0.000000	...	0.000000	0.000000	0.000000	0.000000	0.000000	0.0	0.000000	0.000000	0.000000	
3	z3_data/train/antelope/0b088923b0.jpg	antelope	0.0	0.000000	0.000000	0.0	0.000000	0.000000	0.000000	0.008169	...	0.080545	0.177092	0.000000	0.000000	0.004549	0.000000	0.0	0.000000	0.000000	0.031020
4	z3_data/train/antelope/0c16ef86c0.jpg	antelope	0.0	0.044906	0.000000	0.0	0.000000	0.042623	0.000000	0.000000	...	0.000000	0.020604	0.000000	0.000000	0.000690	0.015890	0.0	0.000000	0.000000	0.006815
...	
4855	z3_data/train/zebra/872a4e6a25.jpg	zebra	0.0	0.000000	0.000000	0.0	0.028271	0.068706	0.000000	0.000000	...	0.019101	0.000000	0.000000	0.000000	0.024716	0.000000	0.0	0.000000	0.000000	0.000000
4856	z3_data/train/zebra/8bc28d0165.jpg	zebra	0.0	0.000000	0.000000	0.0	0.000000	0.181362	0.036063	0.050058	...	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.0	0.000000	0.000000	0.000000
4857	z3_data/train/zebra/94cf638fd.jpg	zebra	0.0	0.000000	0.000000	0.0	0.000000	0.000000	0.000000	0.000000	...	0.000000	0.000000	0.000000	0.000000	0.004161	0.0	0.002034	0.000000	0.000000	
4858	z3_data/train/zebra/96e65ae7f7.jpg	zebra	0.0	0.000000	0.000000	0.0	0.000000	0.000000	0.000000	0.000000	...	0.000000	0.000000	0.000000	0.000000	0.000000	0.0	0.000000	0.000000	0.000000	
4859	z3_data/train/zebra/9c23e26c9d.jpg	zebra	0.0	0.000000	0.009243	0.0	0.003404	0.000000	0.000000	0.009011	...	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.0	0.000000	0.000000	0.109277

- Zhlukovanie príznakov pomocou K-means

Na zhlukovanie príznakov do clustrov som používal metódu k-means. Aby som našiel čo najlepší počet clustrov, využíval som na to metódu "elbow" (laketečová metóda), o ktorej môžeme povedať, že hodnota okolo 40 je vhodná pre výber počtu clustrov.

Na redukciu príznakov som použil korelačný prah 0.6. Príznaky, ktoré mali korelačný koeficient nad túto hodnotu, boli odstránené.



- Zobrazenie množiny obrázkov pre 10 zhľukov

Cluster 3



Cluster 4



Cluster 6



Cluster 11



Cluster 16



Cluster 24



Cluster 27



Cluster 29



Cluster 30



Cluster 36



- Trénovanie klasifikátora RandomForest na pripravených príznakoch

Ako klasifikátor som si vybral RandomForestClassifier. Na nájdenie najlepšieho modelu som vopred definoval hyperparametre a prostredníctvom GridSearchCV s cross-validationou (cv) nastavenou na 3 som trénoval RandomForestClassifier. Na najlepšom modeli som vyhodnotil trénovací dataset a testovací dataset. Najlepšie hyperparametre sú: 'max_depth': 50, 'min_samples_leaf': 1,

'min_samples_split': 2, 'n_estimators': 100. Úspešnosť na trénovacom datasete je 1.0 percento, na testovacom datasete je to 0.87 percenta.

Vybrané hyperparametre:

```
param_grid = {  
    'n_estimators': [100],  
    'max_depth': [10, 30, 50],  
    'min_samples_split': [2, 5, 10],  
    'min_samples_leaf': [1, 2, 4]  
}
```

